

UNIVERSITÉ PARIS-SACLAY

L3 — Mathématiques

MEU 259 - Projet — Année 2025–2026

S8 - Le restaurant chinois

Owen CAMILLERI

Maxime HESTERS

Aylan KHEDIMALLAH

Avril 2026

Table des matières

1	Introduction	2
2	Description, simulation et propriétés	2
2.1	Description du processus	2
2.2	Première simulation : occupation des tables	2
2.3	Étude asymptotique du nombre de tables	4
3	Estimation de θ	9
3.1	Estimateur asymptotiquement sans biais	9
3.2	Estimateur du maximum de vraisemblance	10
4	Permutation uniforme : le Secret Santa	12
4.1	Description du problème	12
4.2	Lien avec le processus du restaurant chinois pour $\theta = 1$	13
4.3	Lien avec les permutations aléatoires	13
4.4	Loi uniforme de T et U_N	14
4.5	Lien avec les urnes de Pólya	15
4.5.1	Analogie avec le restaurant chinois	15
4.5.2	Comparaison des dynamiques	15
4.6	Convergence presque sûre de U_N/N	15
4.7	Équivalent de $\mathbb{E}[T]$ lorsque $N \rightarrow \infty$	16
4.8	Comparaison avec $N/\mathbb{E}[B_N]$ et paradoxe apparent	17
4.9	Secret Santa avec dérangements	17
5	Une généralisation et un processus biologique	19
5.1	Vérification du modèle généralisé	19
5.2	Horloges aléatoires et lien formel avec le processus biologique	19
5.3	Estimations asymptotiques du développement de l'organisme	21
	Conclusion	21

1 Introduction

Ce projet a pour objet l'étude d'un processus aléatoire classique, connu sous le nom de *processus du restaurant chinois*. Ce modèle trouve des applications dans des domaines aussi variés que la combinatoire des permutations ou encore la modélisation de processus biologiques.

Le principe est le suivant : des clients arrivent successivement dans un restaurant et s'assoient selon une règle probabiliste paramétrée par un réel $\theta > 0$. Cette règle engendre une partition aléatoire de l'ensemble des clients, dont on cherche à comprendre le comportement asymptotique, à estimer le paramètre θ , et à relier la structure à d'autres objets mathématiques connus.

Ce rapport est organisé en quatre parties. La première décrit et simule le processus, et en établit les propriétés asymptotiques. La deuxième traite l'estimation de θ par deux méthodes différentes. La troisième exploite le lien avec les permutations uniformes pour analyser le problème du Secret Santa. Enfin, la quatrième section introduit une généralisation du processus et son interprétation comme modèle de développement cellulaire.

2 Description, simulation et propriétés

2.1 Description du processus

Définition 2.1 (Processus du restaurant chinois). Soit $\theta > 0$. On considère des clients arrivant successivement dans un restaurant. Lorsque le $(k+1)$ -ème client arrive, k clients sont déjà assis, répartis en tables d'occupation $(n_1, \dots, n_p)$ avec $\sum n_i = k$. Alors :

- avec probabilité $\frac{\theta}{\theta + k}$, il ouvre une nouvelle table (s'assoit seul) ;
- avec probabilité $\frac{n_i}{\theta + k}$, il s'assoit à la table i existante.

Le paramètre θ contrôle la tendance à créer de nouvelles tables : plus θ est grand, plus le processus est *exploratoire* (beaucoup de petites tables), tandis qu'un θ faible favorise le regroupement des clients sur un petit nombre de tables.

Remarque 2.1. On note B_n le nombre de tables occupées après l'arrivée des n premiers clients. La suite (B_n) est croissante et prend ses valeurs dans $\{1, \dots, n\}$.

2.2 Première simulation : occupation des tables

Afin de se familiariser avec le modèle, on commence par simuler directement l'occupation des tables pour différentes valeurs de θ , avec $n = 500$ clients.

Implémentation

L'algorithme repose sur la règle suivante : conditionnellement au fait que le client ne s'assoit pas seul, il choisit la table i avec probabilité n_i/k , proportionnelle à sa taille. On simule ce choix par une variable uniforme et une recherche séquentielle dans le tableau des cumuls.

Résultats et commentaires

On trace pour chaque valeur de $\theta \in \{0,5, 1, 1,5, 10\}$ un diagramme en barres représentant la taille de chaque table numérotée par ordre d'ouverture.




FIGURE 1 – Occupation des tables pour $n = 500$ clients et différentes valeurs de θ .

On observe les comportements suivants à partir d'une seule simulation :

- Pour $\theta = 0,5$, le processus est très concentré : quelques tables accueillent la quasi-totalité des clients (ici, on observe seulement 3 tables). La première table ouverte attire naturellement le plus de monde, créant un effet *boule de neige*.
- Pour $\theta = 1$, on observe plus de tables qu'avec $\theta = 0,5$, et les clients semblent principalement se répartir sur les premières tables.
- Pour $\theta = 10$, de nombreuses tables sont ouvertes et restent de petite taille. Le processus ressemble davantage à une attribution quasi-uniforme : la probabilité d'ouvrir une nouvelle table reste élevée tout au long du processus.

Ces observations illustrent le rôle fondamental de θ : il contrôle le compromis entre *exploration* (nouvelles tables) et *exploitation* (rejoindre une table existante). Cependant, ces résultats ne sont pas très représentatifs car ils reposent sur une seule simulation, qui peut être très aléatoire.

Pour obtenir des conclusions plus robustes, nous allons maintenant simuler le processus B_n (le nombre de tables occupées après n clients) sur un grand nombre de répétitions, afin d'étudier son comportement moyen et sa variabilité.

2.3 Étude asymptotique du nombre de tables

On rappelle que B_n désigne le nombre de tables occupées après l'arrivée des n premiers clients.

Simulations de B_n : Pour étudier le comportement asymptotique de B_n , nous avons simulé ce processus pour différentes valeurs de θ et pour n allant jusqu'à 100 000. Les figures ci-dessous montrent l'évolution de B_n en fonction de n , ainsi que la moyenne empirique de B_n . Ces simulations permettent de visualiser la croissance de B_n et sa variabilité.




FIGURE 2 – Évolution de B_n en fonction de n pour différentes valeurs de θ . Chaque courbe représente une valeur de θ , avec la courbe théorique associée $\theta \log n$

Ces simulations suggèrent que B_n suit une tendance logarithmique, comme attendu théoriquement. Nous allons maintenant étudier formellement son espérance et sa variance.

Décomposition en somme de Bernoulli

Pour tout $k \geq 1$, on introduit la variable aléatoire

$$X_k = \begin{cases} 1 & \text{si le } k\text{-ième client ouvre une nouvelle table,} \\ 0 & \text{sinon.} \end{cases}$$

Alors, par construction,

$$B_n = \sum_{k=1}^n X_k.$$

De plus, pour tout $k \geq 1$,

$$\mathbb{P}(X_k = 1) = \frac{\theta}{\theta + k - 1}.$$

Les variables (X_k) sont indépendantes, car à chaque étape, la décision d'ouvrir une nouvelle table dépend uniquement du nombre de clients déjà présents.

Ainsi, B_n est une somme de variables de Bernoulli indépendantes de paramètres

$$p_k = \frac{\theta}{\theta + k - 1}.$$

Espérance

On a vu que

$$B_n = \sum_{k=1}^n X_k,$$

où les variables (X_k) sont indépendantes et vérifient

$$\mathbb{P}(X_k = 1) = \frac{\theta}{\theta + k - 1}.$$

Ainsi,

$$\mathbb{E}[B_n] = \sum_{k=1}^n \mathbb{E}[X_k] = \sum_{k=1}^n \frac{\theta}{\theta + k - 1}.$$

On pose

$$S_n = \sum_{k=1}^n \frac{\theta}{\theta + k - 1}.$$

Comparaison série-intégrale Considérons la fonction

$$f(x) = \frac{\theta}{\theta + x},$$

qui est décroissante sur $[0, +\infty[$.

Pour tout $k \geq 1$, on a alors

$$\int_k^{k+1} f(x) dx \leq f(k) \leq \int_{k-1}^k f(x) dx.$$

En sommant de $k = 1$ à n , on obtient

$$\int_1^{n+1} f(x) dx \leq S_n \leq \theta + \int_1^n f(x) dx.$$

Calcul des intégrales On calcule

$$\int_a^b \frac{\theta}{\theta + x} dx = \theta \log(\theta + x) \Big|_a^b = \theta \log \left(\frac{\theta + b}{\theta + a} \right).$$

Ainsi,

$$\int_1^{n+1} f(x) dx = \theta \log \left(\frac{\theta + n + 1}{\theta + 1} \right),$$

et

$$\int_1^n f(x) dx = \theta \log \left(\frac{\theta + n}{\theta + 1} \right).$$

Encadrement On en déduit

$$\theta \log \left(\frac{\theta + n + 1}{\theta + 1} \right) \leq S_n \leq \theta + \theta \log \left(\frac{\theta + n}{\theta + 1} \right).$$

Comportement asymptotique Lorsque $n \rightarrow \infty$, on a

$$\log(\theta + n) \sim \log n \quad \text{et} \quad \log(\theta + n + 1) \sim \log n.$$

Par encadrement, on obtient

$$S_n \sim \theta \log n.$$

Conclusion Ainsi,

$$\mathbb{E}[B_n] \sim \theta \log n.$$

Variance

Comme les variables (X_k) sont indépendantes,

$$\text{Var}(B_n) = \sum_{k=1}^n \text{Var}(X_k).$$

Or, pour une variable de Bernoulli,

$$\text{Var}(X_k) = p_k(1 - p_k).$$

Donc

$$\text{Var}(B_n) = \sum_{k=1}^n \frac{\theta}{\theta + k - 1} \left(1 - \frac{\theta}{\theta + k - 1} \right).$$

Pour k grand,

$$\text{Var}(X_k) \sim \frac{\theta}{k}.$$

Ainsi,

$$\text{Var}(B_n) \sim \theta \sum_{k=1}^n \frac{1}{k}.$$

Par le même raisonnement que précédemment,

$$\text{Var}(B_n) \sim \theta \log n.$$

Convergence en probabilité

On souhaite montrer que

$$\frac{B_n}{\log n} \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \theta.$$

On applique l'inégalité de Bienaymé–Tchebychev :

$$\mathbb{P}(|B_n - \mathbb{E}[B_n]| \geq \varepsilon \log n) \leq \frac{\text{Var}(B_n)}{\varepsilon^2 (\log n)^2}.$$

Or,

$$\text{Var}(B_n) \sim \theta \log n,$$

donc

$$\frac{\text{Var}(B_n)}{(\log n)^2} \sim \frac{\theta}{\log n} \xrightarrow[n \rightarrow \infty]{} 0.$$

Ainsi,

$$\frac{B_n - \mathbb{E}[B_n]}{\log n} \xrightarrow{\mathbb{P}} 0.$$

Comme

$$\frac{\mathbb{E}[B_n]}{\log n} \rightarrow \theta,$$

on obtient finalement

$$\frac{B_n}{\log n} \xrightarrow{\mathbb{P}} \theta.$$

Convergence presque sûre ? Étude expérimentale

On peut se demander si la convergence précédente est presque sûre, c'est-à-dire si

$$\frac{B_n}{\log n} \xrightarrow[n \rightarrow \infty]{\text{p.s.}} \theta.$$

Pour explorer cette question, on utilise la fonction de simulation introduite précédemment, et on observe l'évolution de la quantité

$$\frac{B_n}{\log n}$$

au cours du temps, pour une trajectoire donnée.

Simulation On trace la courbe de $B_n/\log n$ en fonction de n .




FIGURE 3 – Évolution de $B_n/\log n$ en fonction de n .

Observations Les simulations montrent que la quantité $B_n/\log n$ reste proche de θ , mais continue de fluctuer de manière persistante, même pour des valeurs de n très grandes.

Ces fluctuations ne semblent pas s'atténuer suffisamment pour suggérer une convergence presque sûre vers θ . La trajectoire oscille autour de la valeur θ sans s'en rapprocher de façon stable.

Conclusion Ces observations suggèrent qu'il n'y a pas de convergence presque sûre de $\frac{B_n}{\log n}$ vers θ , mais seulement une convergence en probabilité.

Fluctuations asymptotiques et théorème central limite

On cherche maintenant à décrire plus finement les fluctuations de B_n autour de son espérance.

On pose

$$a_n = \theta \log n \quad \text{et} \quad b_n = \sqrt{\theta \log n}.$$

On considère alors la variable centrée et réduite

$$\frac{B_n - a_n}{b_n}.$$

Comme B_n est une somme de variables de Bernoulli indépendantes (X_k) , on peut appliquer un théorème central limite pour suites de variables indépendantes.

En effet,

$$B_n = \sum_{k=1}^n X_k,$$

avec

$$\sum_{k=1}^n \text{Var}(X_k) \sim \theta \log n = b_n^2.$$

On en déduit que

$$\frac{B_n - \theta \log n}{\sqrt{\theta \log n}} \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \mathcal{N}(0, 1).$$

Ici, on applique une autre version du TCL classique vu en L3, car ici, les variables ne sont pas iid, donc les conditions du Théorème Central Limite "classique" ne sont pas vérifiées.

3 Estimation de θ

Dans cette partie, on suppose que le paramètre θ est inconnu, et on cherche à l'estimer à partir de l'observation du processus (B_n) .

3.1 Estimateur asymptotiquement sans biais

Construction de l'estimateur On a montré dans la partie précédente que

$$\mathbb{E}[B_n] \sim \theta \log n.$$

Cette relation suggère naturellement de considérer l'estimateur

$$\hat{\theta}_n = \frac{B_n}{\log n}.$$

Propriété asymptotique On calcule l'espérance de cet estimateur :

$$\mathbb{E}[\hat{\theta}_n] = \frac{\mathbb{E}[B_n]}{\log n}.$$

Or, comme

$$\mathbb{E}[B_n] \sim \theta \log n,$$

on obtient

$$\mathbb{E}[\hat{\theta}_n] \sim \frac{\theta \log n}{\log n} = \theta.$$

Conclusion Ainsi, l'estimateur $\hat{\theta}_n$ est asymptotiquement sans biais :

$$\mathbb{E}[\hat{\theta}_n] \xrightarrow[n \rightarrow \infty]{} \theta.$$

De plus, comme on a montré précédemment que

$$\frac{B_n}{\log n} \xrightarrow{\mathbb{P}} \theta,$$

on en déduit que $\hat{\theta}_n$ est également un estimateur consistant.

3.2 Estimateur du maximum de vraisemblance

On cherche maintenant à déterminer l'estimateur du maximum de vraisemblance de θ à partir de l'observation de $(B_1, \dots, B_n)$.

Vraisemblance On rappelle que

$$B_n = \sum_{k=1}^n X_k,$$

où les variables (X_k) sont indépendantes et

$$\mathbb{P}(X_k = 1) = \frac{\theta}{\theta + k - 1}.$$

La vraisemblance s'écrit donc

$$L(\theta) = \prod_{k=1}^n \left(\frac{\theta}{\theta + k - 1} \right)^{X_k} \left(\frac{k - 1}{\theta + k - 1} \right)^{1 - X_k}.$$

Log-vraisemblance On considère la log-vraisemblance :

$$\ell(\theta) = \log L(\theta).$$

On obtient

$$\ell(\theta) = \sum_{k=1}^n [X_k \log \theta - \log(\theta + k - 1) + (1 - X_k) \log(k - 1)].$$

Les termes ne dépendant pas de θ peuvent être ignorés, d'où

$$\ell(\theta) = \sum_{k=1}^n [X_k \log \theta - \log(\theta + k - 1)] + \text{constante}.$$

Dérivation On dérive :

$$\ell'(\theta) = \sum_{k=1}^n \left[\frac{X_k}{\theta} - \frac{1}{\theta + k - 1} \right].$$

On regroupe :

$$\ell'(\theta) = \frac{1}{\theta} \sum_{k=1}^n X_k - \sum_{k=1}^n \frac{1}{\theta + k - 1}.$$

Or,

$$\sum_{k=1}^n X_k = B_n,$$

donc

$$\ell'(\theta) = \frac{B_n}{\theta} - \sum_{k=1}^n \frac{1}{\theta + k - 1}.$$

Équation du maximum de vraisemblance En annulant la dérivée :

$$\frac{B_n}{\theta} = \sum_{k=1}^n \frac{1}{\theta + k - 1},$$

soit

$$B_n = \sum_{k=1}^n \frac{\theta}{\theta + k - 1}.$$

Unicité et de la nature du point critique Pour justifier que cette solution est bien un maximum global et qu'elle est unique, considérons les points suivants :

- La fonction $f(\theta) = \sum_{k=0}^n \frac{\theta}{\theta + k}$ est **strictement croissante** en θ , car chaque terme $\frac{\theta}{\theta + k}$ est croissant en θ .
- Lorsque $\theta \rightarrow 0^+$, $f(\theta) \rightarrow 0$, et lorsque $\theta \rightarrow +\infty$, $f(\theta) \rightarrow n+1$. Comme B_n prend ses valeurs dans $\{1, 2, \dots, n\}$, l'équation $B_n = f(\theta)$ admet donc **une unique solution** $\tilde{\theta}_n$.
- La dérivée seconde de la log-vraisemblance est :

$$\ell''(\theta) = -\frac{B_n}{\theta^2} + \sum_{k=1}^n \frac{1}{(\theta + k - 1)^2}.$$

Pour $\theta > 0$, on a $\ell''(\theta) < 0$ (car $\frac{B_n}{\theta^2}$ domine), ce qui montre que la log-vraisemblance est **concave**. Le point critique trouvé est donc bien un **maximum global**.

Conclusion L'estimateur du maximum de vraisemblance $\tilde{\theta}_n$ est donc l'unique solution de

$$B_n = \sum_{k=0}^n \frac{\tilde{\theta}_n}{\tilde{\theta}_n + k}.$$

Comparaison des estimateurs On compare deux estimateurs de θ :

$$\hat{\theta}_n = \frac{B_n}{\log n} \quad \text{et} \quad \tilde{\theta}_n.$$

L'estimateur $\hat{\theta}_n$ est simple à calculer mais repose sur un résultat asymptotique, tandis que l'estimateur du maximum de vraisemblance est en général plus précis.

Les simulations montrent que les deux estimateurs convergent vers θ , mais que $\tilde{\theta}_n$ est plus stable pour des tailles finies.




FIGURE 4 – Comparaison des estimateurs de θ en fonction de n .

4 Permutation uniforme : le Secret Santa

4.1 Description du problème

On considère un groupe de N personnes organisant un *Secret Santa*. Le principe est le suivant : chaque personne offre un cadeau à une autre personne, de telle sorte que chacun donne et reçoit exactement un cadeau.

Mathématiquement, cela revient à tirer une permutation σ uniformément au hasard dans l'ensemble des permutations de $\{1, \dots, N\}$. La personne i offre alors son cadeau à $\sigma(i)$.

Lors de l'échange, on procède de la manière suivante : la personne 1 donne son cadeau à $\sigma(1)$, puis la personne $\sigma(1)$ donne son cadeau à $\sigma(\sigma(1))$, et ainsi de suite. On s'intéresse

au nombre d'étapes nécessaires pour que la personne 1 reçoive finalement son propre cadeau. On note ce temps T .

Ce temps correspond exactement à la taille du cycle de la permutation σ contenant l'élément 1.

4.2 Lien avec le processus du restaurant chinois pour $\theta = 1$

On considère maintenant le processus du restaurant chinois dans le cas particulier $\theta = 1$.

Dans ce cas, la règle devient :

- le client $k + 1$ ouvre une nouvelle table avec probabilité $\frac{1}{k + 1}$;
- sinon, il rejoint une table existante avec probabilité proportionnelle à sa taille.

4.3 Lien avec les permutations aléatoires

Dans le cas particulier où le paramètre $\theta = 1$, le processus du restaurant chinois établit une correspondance avec la structure des cycles d'une permutation aléatoire uniforme de l'ensemble $\{1, \dots, N\}$.

- **Tables et cycles** : Chaque table occupée dans le restaurant correspond à un cycle distinct de la permutation. Autrement dit, le nombre de tables occupées après l'arrivée de N clients est égal au nombre de cycles dans la décomposition de la permutation aléatoire.
- **Taille des tables et longueur des cycles** : La taille n_i de la table i (c'est-à-dire le nombre de clients assis à cette table) est égale à la longueur du cycle i dans la permutation. Par exemple, une table avec 4 clients correspond à un cycle de longueur 4 dans la permutation.
- **Client 1 et cycle contenant 1** : La taille de la table à laquelle le premier client (client 1) est assis a exactement la même loi que la longueur du cycle contenant l'élément 1 dans la permutation aléatoire. Cela signifie que si l'on note U_N la taille de la table contenant le client 1 après l'arrivée de N clients, alors U_N suit la même distribution que la longueur du cycle contenant 1 dans une permutation aléatoire de $\{1, \dots, N\}$.

Conséquence directe : La variable aléatoire T , qui représente le temps nécessaire pour que le client 1 reçoive son cadeau dans le cadre du Secret Santa, est donc distribuée de la même manière que U_N :

$$T \stackrel{(d)}{=} U_N.$$

4.4 Loi uniforme de T et U_N

On montre maintenant que la variable aléatoire T , représentant la longueur du cycle contenant l'élément 1 dans une permutation aléatoire uniforme de $\{1, 2, \dots, N\}$, suit une loi uniforme sur $\{1, 2, \dots, N\}$.

- Le nombre total de permutations de N éléments est $N!$.
- Pour tout $k \in \{1, 2, \dots, N\}$, le nombre de permutations où le cycle contenant 1 a une longueur exactement k est $(N-1)!$.
- On choisit $k-1$ éléments parmi les $N-1$ restants pour former le cycle avec 1 : $\binom{N-1}{k-1}$ choix.
- On arrange ces k éléments en un cycle : $(k-1)!$ façons.
- On permute les $N-k$ éléments restants : $(N-k)!$ façons.
- Le produit est $\binom{N-1}{k-1} \times (k-1)! \times (N-k)! = (N-1)!$.
- La probabilité que $T = k$ est donc :

$$\mathbb{P}(T = k) = \frac{(N-1)!}{N!} = \frac{1}{N}.$$

Conclusion La variable T suit une loi uniforme sur $\{1, 2, \dots, N\}$. Comme $T \stackrel{(d)}{=} U_N$, la taille de la table contenant le client 1 dans le processus du restaurant chinois pour $\theta = 1$ suit également une loi uniforme sur $\{1, 2, \dots, N\}$.




FIGURE 5 – Correspondance entre les tables du restaurant chinois et les cycles d'une permutation.

4.5 Lien avec les urnes de Pólya

Considérons une urne de Pólya initiale contenant une boule rouge et une boule bleue. À chaque étape $n + 1$, on tire une boule au hasard et on la remplace en ajoutant une boule de la même couleur. Soit R_n le nombre de boules rouges à l'étape n . La dynamique de l'urne est la suivante :

- Avec probabilité $\frac{R_n}{n}$, on tire une boule rouge, et on ajoute une boule rouge supplémentaire. Ainsi, $R_{n+1} = R_n + 1$.
- Avec probabilité $\frac{B_n}{n} = \frac{n-R_n}{n}$, on tire une boule bleue, et on ajoute une boule bleue supplémentaire. Ainsi, $R_{n+1} = R_n$.

4.5.1 Analogie avec le restaurant chinois

Dans le processus du restaurant chinois avec $\theta = 1$, notons U_n le nombre de personnes à la table 1 après l'arrivée de n clients. La dynamique de U_n est la suivante :

- Le $(n + 1)$ -ème client s'assoit à la table 1 avec probabilité $\frac{U_n}{n}$ (car la probabilité de s'asseoir à une table est proportionnelle au nombre de clients déjà assis à cette table). Dans ce cas, $U_{n+1} = U_n + 1$.
- Sinon, le $(n + 1)$ -ème client s'assoit à une autre table ou à une nouvelle table, et $U_{n+1} = U_n$.

4.5.2 Comparaison des dynamiques

Les deux processus partagent la même dynamique probabiliste :

$$\begin{cases} P(R_{n+1} = R_n + 1) = \frac{R_n}{n}, \\ P(R_{n+1} = R_n) = \frac{n-R_n}{n}, \end{cases}$$

et

$$\begin{cases} P(U_{n+1} = U_n + 1) = \frac{U_n}{n}, \\ P(U_{n+1} = U_n) = \frac{n-U_n}{n}. \end{cases}$$

De plus, les deux processus partagent la même **condition initiale** :

$$U_1 = R_1 = 1.$$

Ainsi, les processus $(R_n)_{n \geq 1}$ et $(U_n)_{n \geq 1}$ sont identiques en loi. Cela signifie que le nombre de personnes à la table 1 dans le restaurant chinois suit la même distribution que le nombre de boules rouges dans l'urne de Pólya.

4.6 Convergence presque sûre de U_N/N

On utilise le modèle de l'urne de Pólya pour étudier la convergence de U_N/N .

Lien avec l'urne de Pólya Le processus du restaurant chinois pour $\theta = 1$ est équivalent à une urne de Pólya contenant initialement une boule rouge (la table du client 1) et une boule bleue (les autres tables). À chaque étape :

- Si on tire une boule rouge, on la remplace par deux boules rouges.
- Si on tire une boule bleue, on la remplace par une boule rouge et une boule bleue.

Ainsi, si à l'étape N il y a a boules rouges et b boules bleues, alors à l'étape $N + 1$:

- Avec probabilité $\frac{a}{a+b}$, on a $a + 1$ boules rouges.
- Avec probabilité $\frac{b}{a+b}$, on a a boules rouges.

L'espérance du nombre de boules rouges à l'étape $N + 1$ sachant l'étape N est donc :

$$\mathbb{E}[a_{N+1} | a_N = a] = a.$$

Utilisation des martingales Une martingale est un processus aléatoire (M_N) tel que $\mathbb{E}[M_{N+1} | M_N] = M_N$. Ici, le nombre de boules rouges (a_N) est une martingale car :

$$\mathbb{E}[a_{N+1} | a_N] = a_N.$$

Loi limite Dans le cas de l'urne de Pólya avec une boule rouge et une boule bleue initialement, la loi limite de M_∞ est la loi uniforme sur $[0, 1]$. Ainsi :

$$\frac{U_N}{N} \xrightarrow[N \rightarrow \infty]{p.s.} M_\infty,$$

où M_∞ suit une loi uniforme sur $[0, 1]$.

Interprétation Cela signifie que, dans le cadre du restaurant chinois pour $\theta = 1$, la proportion de clients à la table du client 1 converge presque sûrement vers une variable aléatoire uniformément distribuée entre 0 et 1.

4.7 Équivalent de $\mathbb{E}[T]$ lorsque $N \rightarrow \infty$

On cherche un équivalent de l'espérance $\mathbb{E}[T]$ lorsque $N \rightarrow \infty$, où T est la longueur du cycle contenant l'élément 1 dans une permutation aléatoire uniforme de $\{1, 2, \dots, N\}$.

Loi de T On a montré que T suit une loi uniforme sur $\{1, 2, \dots, N\}$. Ainsi, pour tout $k \in \{1, 2, \dots, N\}$, on a :

$$\mathbb{P}(T = k) = \frac{1}{N}.$$

Calcul de $\mathbb{E}[T]$ L'espérance de T est donnée par :

$$\mathbb{E}[T] = \sum_{k=1}^N k \cdot \mathbb{P}(T = k) = \frac{1}{N} \sum_{k=1}^N k = \frac{1}{N} \cdot \frac{N(N+1)}{2} = \frac{N+1}{2}.$$

Équivalent asymptotique Pour N grand, on obtient l'équivalent suivant :

$$\mathbb{E}[T] = \frac{N+1}{2} \sim \frac{N}{2}.$$

Interprétation Cela signifie que, en moyenne, la longueur du cycle contenant l'élément 1 dans une permutation aléatoire uniforme de taille N est de l'ordre de $N/2$ lorsque N devient grand.

4.8 Comparaison avec $N/\mathbb{E}[B_N]$ et paradoxe apparent

On compare maintenant l'équivalent de $\mathbb{E}[T]$ avec une estimation de la taille d'une table typique dans le restaurant chinois.

Rappel des résultats

- L'espérance de T est $\mathbb{E}[T] \sim \frac{N}{2}$.
- Le nombre moyen de tables est $\mathbb{E}[B_N] \sim \log N$, donc une estimation de la taille d'une table typique serait $\frac{N}{\mathbb{E}[B_N]} \sim \frac{N}{\log N}$.

Comparaison Il y a une différence marquée entre ces deux quantités :

- $\mathbb{E}[T] \sim \frac{N}{2}$ est d'ordre N .
- $\frac{N}{\log N}$ est d'ordre $N/\log N$, beaucoup plus petit que N pour N grand.

Explication du "paradoxe" :

Cette différence n'est pas un vrai paradoxe, mais reflète la **distribution très déséquilibrée des tailles de tables** dans le processus du restaurant chinois :

- La taille moyenne d'une table ($N/\log N$) est petite car il y a beaucoup de petites tables.
- Cependant, la taille moyenne du cycle contenant 1 ($N/2$) est grande car ce cycle a une chance significative d'être l'un des rares grands cycles dans la permutation.

Interprétation Dans le restaurant chinois, la plupart des tables sont petites, mais il y a quelques tables très grandes. Le cycle contenant 1 a une probabilité non négligeable d'être l'une de ces grandes tables, ce qui explique pourquoi sa taille moyenne est bien plus grande que la taille moyenne d'une table "typique".

4.9 Secret Santa avec dérangements

Pour éviter qu'une personne tire son propre nom dans le Secret Santa, il est plus judicieux de choisir σ parmi les permutations sans point fixe, appelées **dérangements**.

Définition Un dérangement est une permutation σ de $\{1, 2, \dots, N\}$ telle que $\sigma(i) \neq i$ pour tout i . Le nombre de dérangements de N éléments est donné par :

$$!N = N! \sum_{k=0}^N \frac{(-1)^k}{k!}.$$

Simulation On simule le processus du Secret Santa pour des permutations uniformes et pour des dérangements, et on compare la longueur du cycle contenant 1 (notée T) dans les deux cas.




FIGURE 6 – Comparaison de la taille du cycle contenant 1 avec permutations et dérangements, avec 50 clients, 10 000 simulations

Interprétation Bien que les dérangements excluent les points fixes, la longueur moyenne du cycle contenant 1 reste similaire à celle des permutations uniformes. Cela montre que la contrainte des dérangements n’affecte pas significativement la taille moyenne des cycles, mais peut modifier légèrement leur distribution.

Pour les dérangements, bien que la contrainte de ne pas avoir de point fixe modifie légèrement la distribution des longueurs de cycle, l’espérance de T reste asymptotiquement proche de celle des permutations uniformes. Ainsi, pour N grand, on a :

$$\mathbb{E}[T] \approx \frac{N}{2}.$$

Justification La raison en est que, pour N grand, la probabilité qu’un élément particulier (comme l’élément 1) soit dans un cycle de longueur donnée est presque la même dans un dérangement que dans une permutation uniforme. La contrainte de ne pas avoir

de points fixes affecte principalement les petits cycles, mais a peu d'impact sur les cycles de grande taille.

Choisir σ parmi les dérangements est une approche plus maline pour le Secret Santa, car elle évite les auto-attributions. Cependant, cela ne change pas radicalement le comportement asymptotique de la longueur des cycles.

5 Une généralisation et un processus biologique

5.1 Vérification du modèle généralisé

Soit un instant où k clients sont répartis sur p tables d'occupations respectives $(n_1, \dots, n_p)$. Les probabilités d'affectation du $(k+1)$ -ème client sont données par :

- $P(\text{table } i) = \frac{n_i - \alpha}{k + \theta}$ pour $i \in \{1, \dots, p\}$.
- $P(\text{nouvelle table}) = \frac{\theta + p\alpha}{k + \theta}$.


Vérification de la loi de probabilité : La somme de ces probabilités doit valoir 1.

$$\sum_{i=1}^p \left(\frac{n_i - \alpha}{k + \theta} \right) + \frac{\theta + p\alpha}{k + \theta} = \frac{\sum_{i=1}^p n_i - p\alpha + \theta + p\alpha}{k + \theta}.$$

Puisque la somme des effectifs des tables est le nombre total de clients $\sum_{i=1}^p n_i = k$, on obtient bien :

$$\frac{k - p\alpha + \theta + p\alpha}{k + \theta} = \frac{k + \theta}{k + \theta} = 1.$$

Généralisation du restaurant de base : Si l'on fixe $\alpha = 0$, on retrouve $P(\text{table } i) = \frac{n_i}{k + \theta}$ et $P(\text{nouvelle table}) = \frac{\theta}{k + \theta}$, ce qui correspond rigoureusement au modèle initial du restaurant chinois.



5.2 Horloges aléatoires et lien formel avec le processus biologique

Analysons le modèle biologique en temps continu décrit par des horloges exponentielles. Considérons l'état du système à l'instant où l'organisme contient exactement k cellules,

réparties en p types (organes) de tailles $(n_1, \dots, n_p)$.

Par construction du modèle, chaque organe de taille n_i est constitué d'exactlyement **1 cellule-souche** (la fondatrice) et de $n_i - 1$ **cellules-clones**.

Calculons l'intensité (le taux) d'occurrence pour chaque événement de naissance possible :

1. Création d'une nouvelle cellule-clone dans l'organe i (agrandissement de la table i) :

- La cellule-souche de type i produit un clone avec une intensité $1 - \alpha$.
- Chacune des $(n_i - 1)$ cellules-clones de type i produit un clone avec une intensité 1.

L'intensité totale de création d'un clone pour l'organe i est donc :

$$\lambda_{\text{clone},i} = (1 - \alpha) + (n_i - 1) \times 1 = n_i - \alpha.$$

2. Création d'une nouvelle cellule-souche d'un type inédit (création d'une nouvelle table) :

- L'horloge globale produit de nouvelles souches avec une intensité θ .
- Chacune des p cellules-souches existantes produit une nouvelle souche d'un type nouveau avec une intensité α .

L'intensité totale de création d'un nouvel organe est :

$$\lambda_{\text{nouvel organe}} = \theta + p\alpha.$$

Probabilités de transition de la chaîne de Markov incluse : L'intensité totale Λ de création d'une cellule (quelle qu'elle soit) est la somme de toutes les intensités :

$$\Lambda = \lambda_{\text{nouvel organe}} + \sum_{i=1}^p \lambda_{\text{clone},i} = (\theta + p\alpha) + \sum_{i=1}^p (n_i - \alpha) = \theta + p\alpha + \left(\sum_{i=1}^p n_i \right) - p\alpha.$$

Puisque $\sum n_i = k$, on a $\Lambda = k + \theta$.

La probabilité que le prochain événement (la $(k + 1)$ -ème cellule) soit un ajout à l'organe i est le rapport de l'intensité de cet événement sur l'intensité totale :

$$P(\text{ajout à l'organe } i) = \frac{\lambda_{\text{clone},i}}{\Lambda} = \frac{n_i - \alpha}{k + \theta}.$$

La probabilité que le prochain événement soit la création d'un nouvel organe est :

$$P(\text{nouvel organe}) = \frac{\lambda_{\text{nouvel organe}}}{\Lambda} = \frac{\theta + p\alpha}{k + \theta}.$$

Conclusion : La suite discrète des naissances de cellules et de leurs affectations aux différents organes suit rigoureusement la loi du processus du restaurant chinois généralisé

de paramètres (α, θ) .

5.3 Estimations asymptotiques du développement de l'organisme

L'introduction du paramètre $\alpha > 0$ modifie fondamentalement la dynamique du système asymptotique par rapport au modèle classique ($\alpha = 0$).

Évolution du nombre d'organes (le nombre de tables B_k) : Déterminons l'espérance conditionnelle du nombre d'organes à l'étape $k + 1$:

$$\mathbb{E}[B_{k+1}|\mathcal{F}_k] = B_k + P(\text{nouvelle table à l'étape } k+1) = B_k + \frac{\theta + B_k\alpha}{k + \theta}.$$

En prenant l'espérance totale :

$$\mathbb{E}[B_{k+1}] = \mathbb{E}[B_k] \left(1 + \frac{\alpha}{k + \theta}\right) + \frac{\theta}{k + \theta}.$$

Contrairement à la récurrence $\mathbb{E}[B_{k+1}] = \mathbb{E}[B_k] + \frac{\theta}{k+\theta}$ du cas $\alpha = 0$ qui donne une croissance logarithmique $\sim \theta \ln k$, le terme multiplicatif dominant ici est $(1 + \frac{\alpha}{k})$. Par développement asymptotique (similaire à l'étude de la fonction Gamma), on montre que le nombre d'organes croît selon une **loi de puissance** :

$$\mathbb{E}[B_k] \sim C \cdot k^\alpha \quad (k \rightarrow \infty),$$

où C dépend de θ et α . Presque sûrement, $\frac{B_k}{k^\alpha}$ converge vers une variable aléatoire suivant une loi de Mittag-Leffler. Le paramètre α contrôle ainsi l'explosion de la diversité structurelle de l'organisme.

Évolution de la taille des organes : Puisqu'il y a au total k cellules réparties en un ordre de grandeur de k^α organes, la taille moyenne d'un organe (d'une table) est asymptotiquement :

$$\text{Taille moyenne} \approx \frac{k}{B_k} \sim k^{1-\alpha}.$$

Le processus de Pitman-Yor est bien connu pour générer des partitions exhibant un comportement structurel de type *loi de puissance* (power-law). Cela traduit biologiquement le fait que quelques organes très anciens (créés dans les premières étapes) vont drainer la majorité des cellules (macroscopiques), tandis qu'une myriade de micro-organes récents ne comporteront que très peu de cellules.

Conclusion

Dans ce projet, nous avons étudié en détail le processus du restaurant chinois, un modèle probabiliste fondamental permettant de générer des partitions aléatoires d'un

ensemble. Nous avons mis en évidence l'influence du paramètre $\theta > 0$, à travers des simulations et l'étude asymptotique du nombre de tables B_n .

Nous avons ensuite proposé deux estimateurs de θ : l'un asymptotiquement sans biais, l'autre du maximum de vraisemblance et comparé leurs performances. La mise en relation avec les permutations uniformes (problème du *Secret Santa*) a permis d'interpréter le cas $\theta = 1$ comme un cycle aléatoire uniforme, et de lever un apparent paradoxe sur la taille moyenne des tables.

Enfin, la généralisation du processus (modèle de Pitman–Yor) introduit un second paramètre α , dont nous avons montré qu'il modifie radicalement le comportement asymptotique : le nombre de tables croît alors comme une puissance k^α , ce qui trouve une interprétation naturelle en biologie du développement.

Ce projet illustre ainsi la richesse des processus de renforcement, leur lien avec la combinatoire, la statistique et la modélisation biologique. Il peut ouvrir la voie à des prolongements tels que l'estimation conjointe de (θ, α) .

Convergence presque-sûr ? Pour $n = 10^6$ on observe toujours des oscillations “aléatoires” autour de θ